




기사

# 컨볼루션을 이용한 예방적 자율주행차 블랙아이스 사고 감지 원문보기 KCI 원문보기 인용 신경망

이호준<sup>1</sup>, 강민희<sup>2</sup>

, 송재인<sup>삼</sup>

 그리고 황기연<sup>1,\*</sup>

<sup>1</sup> 홍익대학교 도시설계학과, 서울 04066, 한국; b513080@naver.com 홍익대학교 대학원 스마트시티학과, Seoul 04066,

<sup>2</sup> Korea; speakbee@hanmail.net 홍익대학교 과학기술연구소, 서울, 04066, 대한민국; woldsthd@nate.com

삼

\* 문의: keith@hongik.ac.kr ; 전화: 010-8654-7415

수신: 2020년 11월 13일; 수락: 2020년 12월 16일; 게시일: 2020년 12월 18일

**추상적인:** 자동화된 차량(AV)은 인간이 운전하는 차량(HV)을 사용할 때 발생하는 교통 사고를 획기적으로 줄일 것으로 기대됩니다. 그러나 AV의 급속한 발전에도 불구하고 이상적인 상황에서도 AV 관련 사고가 발생할 수 있습니다. 따라서 이들의 안전을 강화하기 위해서는 사고에 대한 '예방적 설계'가 지속적으로 요구된다. 이에 AV의 안전성을 높이기 위해서는 사고를 미연에 방지하는 '예방 설계'가 지속적으로 요구된다. 특히 동절기 차량 대형사고의 주요 원인인 육안으로 식별하기 어려운 특성을 지닌 블랙아이스는 자율주행차 시대에 심각한 부상을 초래할 것으로 예상되며 이를 방지하기 위한 대책이 필요하다. 그러므로, 본 연구는 블랙아이스로 인한 AV의 교통사고를 예방하기 위한 CNN(Convolutional Neural Network) 기반 블랙아이스 감지 방안을 제시한다. 특정 환경에서만 형성되는 블랙아이스의 특성상 이미지 데이터를 보강하여 도로 환경 이미지를 학습하였습니다. 테스트 결과 제안된 CNN 모델은 96%의 정확도와 재현성으로 블랙아이스를 감지했습니다. 본 연구에서 제안하는 블랙아이스 감지를 위한 CNN 모델은 AV의 안전성 향상과 블랙아이스 사고를 사전에 예방하는데 기여할 것으로 기대된다.

**키워드:** 자동화 차량; 검은 얼음; CNN; 교통 사고; 방지

## 1. 소개

4차 산업혁명에 대한 논의가 활발해지면서 빅데이터, 인공지능, 5G 등을 활용하려는 움직임이 나타나고 있다. 그 중에서도 다양한 기술이 집약된 자율주행차(Automated Vehicles, AVs)가 교통 분야에서 주목받고 있다. 자율주행차는 취약계층의 이동성 향상, 교통체증 비용 감소 등의 효과를 가져올 것으로 기대되며, 운전자 부주의로 인한 교통사고 예방 차원에서 인적·물적 손실을 최소화할 것으로 기대된다.<sup>1,2</sup>. 현재 구글, 엔비디아, 테슬라 등 다양한 기업들이 AV 시스템을 개발 및 실험하고 있으며, 각국은 자율주행차 상용화를 준비하기 위해 제도적 기반을 재정비하고 있다. 그러나 이러한 노력에도 불구하고 자율주행 상황에서 교통사고가 계속 발생하고 있으며, 2018년 우버의 보행자 사망으로 인해 자율주행차에 대한 사회적 수용성이 대두되고 있다.<sup>삼-5</sup>. 이러한 문제를 근본적으로 해결하기 위해 독일과 미국은 AV에 대한 윤리 지침을 발표했습니다.<sup>6,7</sup>. 가이드라인은 사고를 피하기 위한 AV의 예방적 설계에 대한 정보와 함께 딜레마 상황에 대처하기 위한 원칙을 개발할 필요성을 명시합니다. 자율주행차의 예방적 설계는 수동적 안전 시스템에서 능동적 안전 시스템 연구로 변화하면서 실제 주행 환경에서 발생할 수 있는 위험 관리에 관한 문제이다.<sup>8</sup>. 또한 최근에는 사고예방에 대한 경향이 변화하고 있다.

AV와 관련된 모든 사고 상황을 스스로 학습하여 [9]. 다양한 예방 설계 연구가 진행되고 있으나 겨울철 대규모 교통사고의 주원인인 블랙아이스 사고 예방에 대한 연구는 부족한 실정이다. 블랙아이스는 비와 눈이 먼지와 같은 오염물질과 결합해 도로에 형성되는 얇은 얼음막으로, 육안으로는 식별이 어려워 치명적인 사고로 이어질 가능성이 높다. 블랙아이스는 자율주행차 상용화 시대에도 잠재적 사고요인으로 꼽히는 만큼 이를 사전에 감지해 사고를 미연에 방지할 수 있는 기술이 필요할 것으로 예상된다. 따라서 본 연구에서는 AV 관련 블랙아이스 사고를 예방하기 위한 방안을 제시하기 위해 물체의 영상을 가장 효과적으로 감지하는 것으로 알려진 Convolutional Neural Network 방식을 채택할 것이다.

본 연구는 다음과 같은 순서로 진행된다. 2. 교통 분야에서 CNN(Convolutional Neural Networks) 활용에 대한 연구를 논의하고 이 연구의 차별화를 도출하는 한편, Seciton은 3. 블랙아이스 감지를 위한 CNN 모델 학습 환경을 설정합니다. 세시톤 4. 모델을 통한 학습 결과 파악 및 분석, Seciton 5. 간략한 요약과 함께 시사점과 향후 연구를 제시한다.

## 2. 문헌 검토

본 장에서는 기존의 블랙아이스 감지 방법과 교통 분야에서 CNN을 활용한 연구를 고찰하여 본 연구의 차별성을 도출한다.

### 2.1. 블랙아이스 감지 방법

블랙아이스를 감지하는 방법에는 센서가 포함됩니다. 10-12], 음파 [13,14] 및 광원 [15]. 하비브 타바타바이 외. (2017) [10]는 콘크리트에 내장된 센서를 이용하여 도로와 교량의 블랙아이스, 얼음, 물을 감지하는 연구를 진행했습니다. 본 연구에서는 콘크리트 내부의 스테인레스 스틸 기둥 사이의 전기 저항 변화를 통해 노면 상태를 감지하는 센서를 제안하였다. 다양한 노면 조건에서 실험을 진행한 결과 제안된 센서가 노면 상태를 효과적으로 감지하여 각종 사고를 예방할 수 있음을 제시하였다. Nuerasimuguli ALIMASI et al. (2012) [11]에서 광학 센서와 적외선 온도계로 구성된 블랙아이스 감지기를 개발하는 연구를 진행했습니다. 연구는 홋카이도 세키호쿠고개 주변 국도 39호선에서 진행되었으며, 총 6개의 도로 조건(건조, 습윤, 샤베트, 촘촘한 눈, 윤기나는 압축눈, 블랙아이스)과 난반사 및 반사에 대해 수행되었다. 실험 결과 블랙아이스는 정반사(아르 자형에스) 및 작은 난반사(아르 자형디)를 측정하여 낮은(아르 자형에스/아르 자형디) 값. Youngis E. Abdalla et al. (2017) [12]는 Kinect를 이용하여 블랙아이스를 감지하는 시스템을 제안했습니다. 얼음의 종류(Soft Ice, Wet Snow, Hard Ice, Black Ice)를 분류하고 Kinect를 이용하여 얼음의 두께와 부피를 측정하였다. 실험 결과 카메라에서 0.82m~1.52m 범위에 형성된 얼음의 종류를 구분할 수 있고, 측정된 두께와 부피의 오차율이 매우 낮아 블랙아이스도 키넥트를 활용해 감지할 수 있음을 시사했다. Xinxu Ma et al. (2020) [15]는 3파장 비접촉 광학 기술을 이용한 블랙아이스 감지 방법을 연구했다. 본 연구에서는 3개의 파장(1310nm, 1430nm, 1550nm)을 이용하여 건조, 습윤, 흑빙, 얼음, 설상 상태를 구분하는 실험을 진행하였다. 실험 결과 각 파장별 반사율을 통해 블랙아이스를 감지하는 것을 확인하여 도로상황 감지 장비 개발의 기초자료로 활용될 수 있음을 제시하였다.

### 2.2. 지능형 교통에 딥러닝 적용

현재 인공지능(AI) 방법론은 다양한 분야에서 활용되고 있으며, 교통 분야에서는 차량 및 보행자 감지, 교통표지판 감지, 노면 감지를 위해 이미지 데이터를 활용한 CNN 연구가 활발히 진행되고 있다.

우선 차량 및 보행자 감지를 위해 AlexNet을 이용한 연구 [16,17], VGG(Visual Geometry Group) 16 [18], 마스크 R-CNN [19], 더 빠른 R-CNN [20,21]가 존재하며, Faster R-CNN과 YOLO(You Only Look Once)의 성능 비교 분석 [22,23]. Lele Xie et al.

(2018) [24]는 CNN 기반의 Multi-Directive YOLO(MD-YOLO)를 이용하여 다양한 각도에서 차량 번호판 감지 연구를 진행했습니다. 본 연구에서는 CNN과 MD-YOLO를 결합한 ALMD-YOLO 구조를 제안하고 다양한 모델(ALMD-YOLO, Faster R-CNN, SSD(Single Shot multibox Detector), MD-YOLO 등)의 성능을 비교한 결과, 새로 제안된 ALMD-YOLO가 최고의 성능을 보였다. 또한 모델의 구조가 단순하여 계산 시간이 단축되고 고성능 다방향 번호판 감지 모델을 구축할 수 있음을 시사하였다. Ye Yuet al. (2018) [25]는 차량 모델의 정밀한 분류를 위해 CNN 기반의 Feature Fusion 기반의 FF-CMNET(Car Model Classification Net)을 제안하였다. 위의 연구에서는 자동차 정면 이미지의 상부 특징 추출을 위한 UpNet과 하부 특징 추출을 위한 DownNet을 결합한 FF-CMNET을 활용하였다. 실험 결과 자동차의 미세한 특징 추출 측면에서 전통적인 CNN 방법론(AlexNet, GoogLeNet 및 NIN(Network in Network))보다 더 나은 성능을 보여주었습니다. MH 푸트라 외. (2018) [26]는 YOLO를 사용하여 사람과 자동차를 감지하는 연구를 수행했습니다. 위의 연구에서는 기존의 YOLO 구조와 달리 7개의 컨볼루션 레이어를 사용하여 변형된 YOLO 구조를 제안하고 성능을 비교하였다. 연구 결과, 수정된 YOLO의 11×11 그리드 셀 모델은 기존 YOLO 모델에 비해 mAP가 낮았지만 처리 속도는 더 좋았습니다. 또한 실제 이미지로 테스트한 결과 몸집이 작은 사람과 자동차도 추출이 가능했다.

둘째, 교통표지판 검출의 경우 기본적인 CNN 구조를 이용한 연구가 많이 진행되어 왔다.[27-30], 마스크 R-CNN [31,32], 더 빠른 R-CNN [33,34]. Rongqiang Qian et al. (2016) [35]는 Fast R-CNN을 사용하여 노면의 교통 표지판을 인식하는 연구를 수행했습니다. 모델의 성능을 향상시키기 위해 객체 인식 과정에서 MDER(Maximally Stable Extremal Regions)과 EdgeBoxes 알고리즘을 활용하여 실험을 진행하였다. 실험 결과 Recall rate는 평균 85.58%의 정밀도로 향상되었다. 알렉산더 슈스타노프와 야키모프, P. (2017) [36] 실시간 교통 표지 인식을 위한 CNN 모델 설계 연구를 진행했습니다. 이 연구는 99.94%의 정확도로 수정된 GHT(Generalized Hough Transform) 및 CNN을 사용했습니다. 또한 제안한 알고리즘이 고화질 영상을 실시간으로 처리할 수 있고, 유사한 교통표지판 인식 시스템보다 더 멀리 있는 교통표지판도 정확하게 인식할 수 있음을 확인하였다. 이형수·김경(2018) [37]는 교통 표지판의 경계를 인식하기 위해 CNN을 사용하여 연구를 수행했습니다. 이들은 SSD 아키텍처를 기반으로 CNN을 설계했으며, 기존 연구와 달리 부호의 위치를 추정하고 이를 경계 추정으로 변환하는 방법을 제안했다. 실험을 통해 다양한 유형의 교통 표지판 경계를 빠르게 감지할 수 있음이 확인되었습니다.

마지막으로 노면상태를 파악하고 노면균열을 검출하기 위한 노면탐지 연구를 검토하였다. Juan Carrillo et al. (2020) [38] 및 Guangyuan Pan 외. (2020) [39]는 모두 노면 상태를 식별하는 연구입니다. 위의 연구들은 데이터를 3개와 4개의 클래스로 나누어 CNN 모델의 성능을 비교하였다. 연구에 따르면 최대 91%의 정확도가 도출되었으며 CNN은 노면 식별에서 탁월한 성능을 보였습니다. 도로 균열 감지 연구에서 Janpreet Singh et al. (2018) [40]는 Mask R-CNN을 이용하여 스마트폰으로 촬영한 이미지에서 도로 파손을 감지하는 연구를 진행했습니다. 데이터는 스마트폰으로 촬영한 9053개의 도로 파손 영상을 활용했고, CNN의 구조는 Mask R-CNN을 활용했다. 실험을 통해 도로 손상이 효과적으로 감지되어 높은 정확도와 0.1초의 처리 속도를 보이는 것을 확인했습니다. Zheng Tong et al. (2018) [41]는 DCNN(Deep Convolutional Neural Networks)을 이용하여 아스팔트 균열의 길이를 분류하는 연구를 진행했습니다. 데이터 수집은 다양한 장소와 기상 조건에서 이루어졌으며, 데이터는 0cm에서 8cm까지 1cm 단위로 8등급으로 구분되었다. 실험결과 정확도는 94.36%, 최대길이오차는 1cm로 단순균열의 유무와 함께 균열의 길이를 구분할 수 있음을 시사하였다. Baoxian Li et al. (2020) [42]는 CNN을 사용하여 도로 균열 유형을 분류하는 연구를 수행했습니다. 도로균열은 총 5가지 유형(비균열, 횡균열, 경도균열, 블록균열, 악어균열)으로 분류하고 기본 CNN 구조를 이용하여 4가지 모델을 설계하였다. 실험 결과, 4개의 정확도

설계된 모델은 94% 이상이었습니다. 또한 CNN은 7을 가지고 있음을 확인했습니다. ×7 크기의 반응 필드는 크랙 감지를 위한 최선의 선택이었습니다.

### 2.3. 요약

요컨대 확인되었다. 블랙 아이스 감지 연구와 CNN을 활용한 다양한 연구에서 운송 분야에서 진행되고 있습니다. 또한 트랜스에서 CNN에 대한 연구 이동 부문 보행자, 차량, 교통표지판, 노면 등 도로 환경을 구성하는 가장 중요한 객체를 감지하기 위해 진행되었으며, CNN을 이용한 객체 감지는 빠른 처리 속도와 높은 정확도를 보여줍니다. 이러한 연구에도 불구하고 기존의 블랙아이스 감지 시스템 설치 등의 문제점으로 인해 블랙아이스 사고를 사전에 예방하는 데는 한계가 있을 것으로 예상된다. 이에 본 연구에서는 AV에서 블랙아이스 사고를 예방하기 위해 CNN 기법을 기반으로 도로 상황을 파악하여 블랙아이스를 감지하는 방법을 제안한다.

## 3. 학습환경 설정

CNN은 1998년 Yann LeCun이 LeNet-5 [43]. CNN은 기존 인공신경망(ANN)에 합성 레이어와 풀링 레이어를 추가해 차원 특성을 파악해 이미지에 공간 정보를 유지·전달하는 기능으로 이미지 분석 분야에서 가장 대중적인 방법론 중 하나다. 앞서 살펴본 바와 같이 교통 분야에서 CNN을 활용한 다양한 연구들이 있지만, 도로 위의 블랙아이스 감지에 대한 연구는 아직까지 검증되지 않았다.

다른 방법론(센서 및 광학) [10-15] AI를 이용한 연구 이외. 블랙아이스는 육안으로는 구분하기 어려운 특징으로 겨울철 대규모 충돌로 이어져 미래 자율주행차 시대의 잠재적 사고요인으로 꼽힌다. 이에 기존의 블랙아이스 검출 방식이 아닌 영상을 이용한 물체 검출에 우수한 성능을 보인다고 평가되는 CNN 기법을 활용하여 블랙아이스 검출을 수행한다.

제안하는 블랙아이스 감지를 위한 CNN 모델의 학습 환경은 크게 데이터 수집 및 전처리, 모델 설계 및 학습 과정으로 구성된다. 본 장에서는 데이터 수집, 1차 전처리, 2차 전처리를 설정하고 모델을 설계하고 학습을 진행하였다 (그림 참조).1).




그림 1. 학습 환경 설정 프로세스.

### 3.1. 데이터 수집 및 전처리

본 장은 블랙아이스 감지 학습을 위한 데이터 수집, 1차 전처리, 2차 전처리로 구성되어 있다.

#### 3.1.1. 데이터 수집

자료 수집에서는 자료 수집 방법과 수집된 자료에 대한 분할을 수행하였다.

##### 1. 데이터 수집

학습을 위해 구글 이미지 검색을 이용하여 이미지 데이터를 수집하였으며, 노면, 젖은 노면, 눈길, 블랙 아이스의 4개 카테고리로 데이터를 수집하였다. 수집 과정에서 다양한 지역과 도로 환경에서 촬영한 영상 데이터를 얻었으며, 표와 같이 총 2230개의 영상 데이터를 수집하였다.1.

1번 테이블. 이미지 데이터의 수.

	도로	젖은 길	스노우로드	검은 얼음	총
숫자	730	610	570	320	2230

## 2. 데이터셋

Google 이미지 검색을 통해 수집된 다양한 지역 및 도로 환경 데이터를 분할합니다. 도로구조물, 차선, 갓길 등의 특징 추출에 방해가 되는 객체를 영상 내에서 제거하여 각 카테고리의 특징을 명확히 파악할 수 있도록 하는 과정입니다. 이 과정에서 데이터의 크기에 따라 장단점이 있었다(표 참조).<sup>2)</sup> 데이터 크기가 작을수록 큰 경우에 비해 이미지 특성을 파악하는 데는 불리하지만, 이미지 수가 많고 심층신경망 구현이 가능한 장점이 있다. 반면에 데이터가 크면 작은 이미지에 비해 이미지의 특징을 명확하게 식별할 수 있기 때문에 특징 추출이 더 정확할 수 있지만 단점은 이미지의 수가 줄어들고 심층 신경망이 구현하기 어렵다. 따라서 본 연구에서는 데이터 크를 128회 실시하였다. × 128px 크기로 심층 신경망과 다수의 이미지를 통해 학습을 진행합니다. 데이터 분할 결과는 그림에 나와 있습니다.<sup>2)</sup>

표 2.(Dis) 데이터 크기에 따른 이점.

	256×256픽셀	128×128픽셀
이점	이미지 특성을 쉽게 식별	많은 수의 이미지 심층 신경망 구현 가능
불리	적은 수의 이미지 심층 신경망을 구현할 수 없음	이미지 특성을 식별하기 어려움



그림 2. 데이터 분할 결과입니다.

### 3.1.2. 1차 전처리

1st Preprocess에서는 학습을 위한 채널 설정 및 데이터 패딩을 수행하였다.

#### 1. 채널 설정

128의 컬러 이미지×데이터를 통해 미리 얻은 128px 나뉜다는 장점이 있다  
3개의 채널 형태로 데이터의 특성을 쉽게 파악할 수 있습니다. 그러나 데이터의 채널이 3개이기 때문에 데이터의 크기가 커서 학습 데이터의 개수와 심층신경망 구현에 한계가 있어 본 연구에서는 데이터를 흑백 이미지 데이터로 변환하여 학습을 수행하였다(참고자료 참조). 테이블삼).



표 3.RGB, GRAYSCALE의 특징.

	RGB	그레이스케일(흑백)
채널 수	3채널	1 채널
특징	큰 데이터 크기	작은 데이터 크기
이점	이미지 특성을 쉽게 식별	학습 데이터 개수 제한 없음 심층 신경망 구현 가능
불리	제한된 수의 학습 데이터 구현 불가능한 심층 신경망	이미지 특성을 식별하기 어려움

## 2. 데이터 패딩

데이터 패딩은 기존 데이터 끝에 공백과 무의미한 기호를 추가하여 학습 이미지의 크기를 조정하는 방법 중 하나입니다. 본 연구의 2차 전처리 과정에서 수행한 Augmentation에서 data padding 없이 학습한 결과, 매우 낮은 정확도(25%)와 높은 loss 값을 확인하였다(Table 4). 이는 데이터 향상으로 인해 이미지 데이터의 가장자리가 왜곡되기 때문입니다. 따라서 본 연구에서는 데이터의 가장자리 왜곡을 방지하기 위해 이미지 데이터를 패딩하였다.

표 4.데이터 확대 및 학습 결과.

		원본 데이터	패딩 데이터
데이터 증대 결과			
학습 결과	손실 정확성	1.39 0.253	0.26 0.891

1차 전처리 과정에서 채널 설정과 데이터 패딩을 진행하면서 150개의 이미지 데이터를×GRAYSCALE 형식의 150px는 다음과 같이 얻었습니다. 4900개의 도로 및 젖은 도로 이미지 데이터와 4900개의 눈길 및 블랙 아이스 이미지 데이터가 있습니다(표5).

표 5.1차 전처리를 통한 데이터 수.

수업	크기	숫자
도로	150×150픽셀	4900
젖은 길		4900
눈길		3900
검은 얼음		3900
총		17,600

### 3.1.3. 2차 전처리

2차 전처리 과정에서 구글 이미지 검색을 통해 더 다양한 이미지 데이터를 수집하는 데는 한계가 있어 정확도를 높이기 위해 데이터 증강을 통해 데이터셋을 구축했다.

AI 학습 모델은 높은 정확성과 과적합 방지를 위해 많은 양의 데이터가 필수적이다.[44]. 특히 본 연구에서 탐지하고자 하는 블랙아이스는 계절적 특성과 많은 장소에서 발생하지 않는 특이한 형성조건이 특징이다. 그 결과 데이터 수집 과정에서 다른 데이터에 비해 많은 양의 데이터가 수집되지 않았다. 따라서 본 연구에서 제안하는 CNN의 정확도를 향상시키기 위해 케라스 라이브러리에서 제공하는 ImageDataGenerator 기능 [45]는 (표6).



표 6.데이터 증가 값 설정.

변환 유형	값
회전	20
너비 이동	0.15
높이 이동	0.15
줌	0.1

광고를 만드는 과정데이터 증대를 통해 설정된  $\alpha$ 는 다음과 같이. 앞서 얻은 17,600장의 데이터에서 클래스별로 무작위로 1000개를 추출하여 테스트 데이터로 설정하였다. 그 이후로 클래스당 10,000개의 데이터를 구축한 나머지 데이터에 대해 ImageDataGenerator 함수를 사용하여 데이터를 보강했습니다. 그런 다음 훈련 데이터와 검증 데이터를 8:2로 설정했습니다. 이에 따라 학습을 진행하기 위해 최종 데이터셋을 모든 수업에서 8:2:1로 설정하였다 (그림3및 표7).

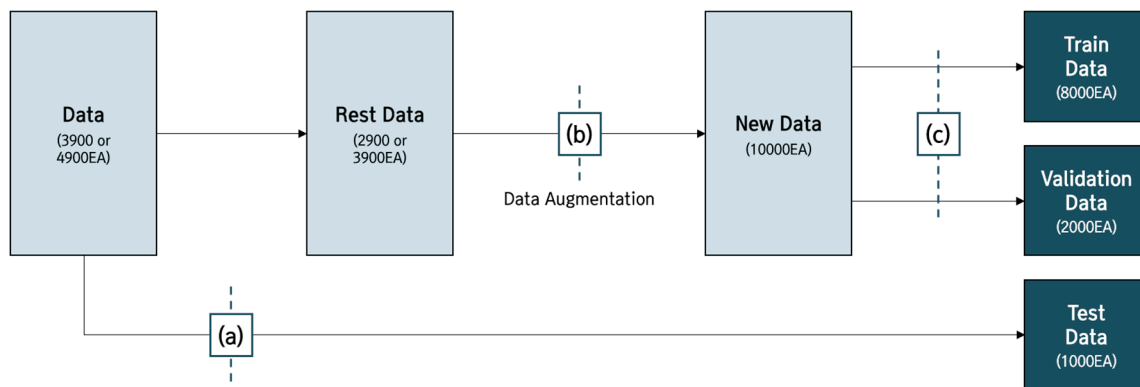


그림 3.(ㄱ) 1000개의 데이터를 무작위로 선택하여 테스트 데이터로 설정합니다. (ㄴ) ImageDataGenerator 함수로 데이터 증대; (ㄷ) 8:2 비율로 설정된 훈련 데이터 및 검증 데이터.

표 7.수업용 데이터세트.

수업	열차 데이터	검증 데이터	테스트 데이터	총
도로 젓은 길 눈길 검은 얼음	8000	2000년	1000	11,000

### 3.2. CNN 설계 및 학습

본 연구에서 사용한 CNN 모델의 구조는 그림과 같이 Feature Extraction과 Classification으로 구성되어 있다.4. 특징추출은 2개의 convolutional layer, 2개의 max-pooling layer, 1개의 dropout layer를 배치하여 2번의 iteration을 수행하도록 하였다.4ㄱ). 그런 다음 각 레이어를 한 번 배열하고 두 번 반복했습니다(그림4비). 또한 학습 속도가 빠르고 기울기 소멸을 방지하는 ReLU(Rectified Linear Unit)를 사용했습니다.46], 활성화 기능으로. 컨볼루션 레이어의 커널 크기의 경우, (3,3

)가 적용되었기 때문에 (3,3)의 반복 학습 속도가 빠르고 특징 추출이 잘됨 [47]. max pooling layer의 Stride는 (2,2), dropout layer의 Dropout rate는 실험적으로 0.2를 적용하였다. 분류에서는 Fully-Connected 계층과 Dropout 계층을 번갈아 가며 배치하였고, 출력 계층에는 Softmax를 적용하였다(그림4c) 높은 실험 정확도를 위해 SGD(Stochastic Gradient Descent) Optimizer를 사용했습니다. 또한 최적화를 위해 200 epochs, 32 batch size 및 earlystopping 기능을 적용했습니다.

e 모델 및 과적합 방지. 조기정지 기능 종료  
있을 때 배움 모델에 개선의 여지가 없습니다. 따라서 우리는 이 연구를 다음과 같이 설계했습니다.  
검증 손실이 20회 이내에 최소값을 업데이트하지 않으면 학습을 중지합니다(표 참조).8)

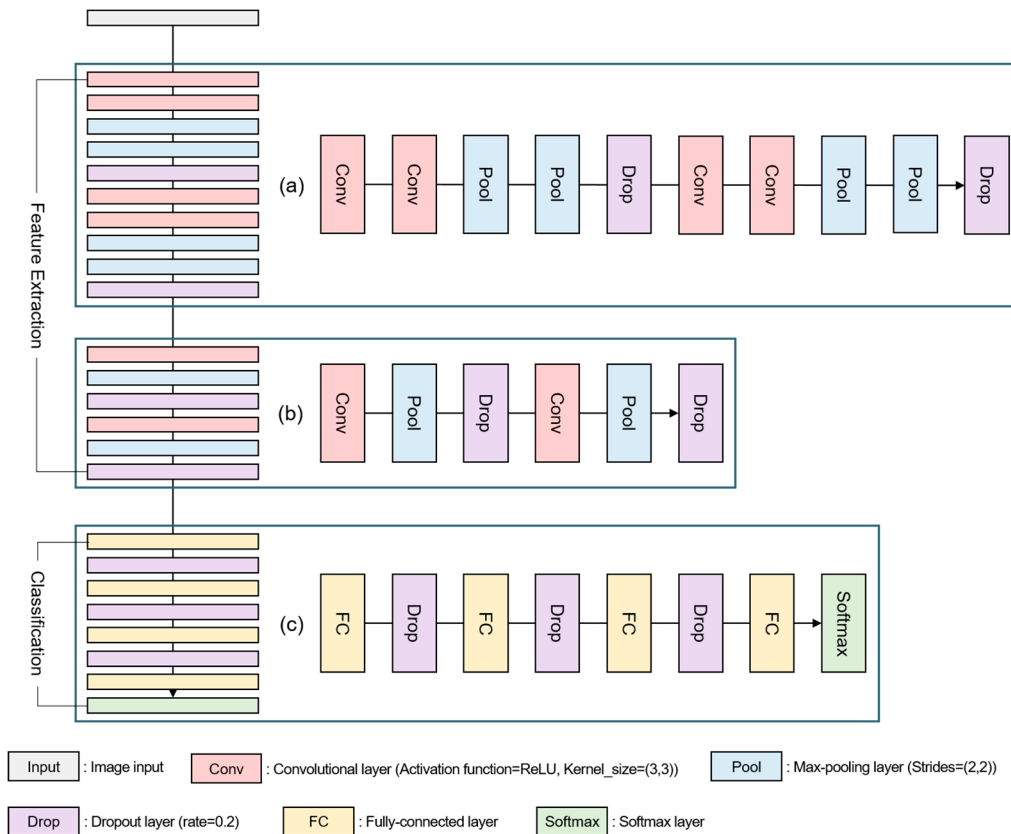


그림 4.CNN 모델 구조; (ㄷ) convolution layer와 max-pooling layer를 두 번 배치한 후 dropout layer를 한 번 배치하고 training을 두 번 반복합니다. (비) 컨벌루션 레이어, 최대 풀링 레이어 및 드롭아웃 레이어를 한 번 배치하고 훈련을 두 번 반복합니다. (씨) fully-connected layer와 dropout layer를 교대로 배치하고 output layer에 softmax를 적용한다.

표 8.CNN 모델 설정값.

수업	값
활성화 기능	릴루
커널 크기	(3,3)
걸음걸이	(2,2)
중퇴율	0.2
옵티마이저	상기포트 달리
시대	200
배치 크기	32
얼리 스톱	20

## 4. 결과

### 4.1. 결과

CNN 모델을 기반으로 열차 데이터와 테스트 데이터의 손실은 각각 0.008과 0.097로 나타났고, 정확도는 각각 0.998과 0.982로 나타났습니다(그림 참조).5및 표9).

보다 상세한 학습 결과 분석을 위해 학습 데이터와 테스트 데이터로 클래스별 성과지표를 파악하였다. 먼저 열차 데이터에 대한 혼동행렬을 분석하여 등급별 분류 결과를 확인하였다. 컨퓨전 매트릭스는 학습을 통한 예측 성능을 측정하기 위해 예측된 클래스와 실제 클래스를 비교하기 위한 매트릭스로, 엑스-예측된 클래스를 나타내는 축과 와이-실제 클래스를 나타내는 축. Confusion matrix의 결과



(수치6) 실제 클래스  
w를 보여주었다

w 도로, 그리고 언제




그림 5. 학습 결과: (a) 다 엑스-왼쪽 그래프의 축은 Epoch의 값을 나타냅니다. 와이-축은 손실 값을 나타냅니다. (b) 엑스-오른쪽 그래프의 축은 Epoch를 나타내고, 와이-축은 정확도를 나타냅니다.

표 9. 교육 결과.

수업	손실	정확성
기차	0.008	0.998
시험	0.097	0.982

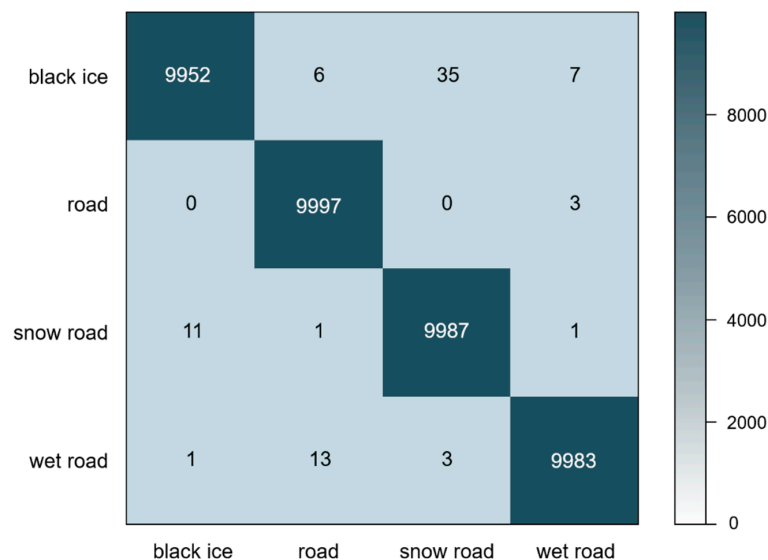


그림 6. 혼동행렬; 학습을 통해 예측 성능을 측정하기 위해 작성된 행렬, 엑스-축은 예측된 클래스를 나타내고 와이-axis는 실제 클래스를 나타냅니다. 결과는 (x,y) = (눈길, 블랙아이스) = 35, (블랙아이스, 눈길) = 11, (도로, 젖은 길) = 13으로 나타났다.

둘째, 각 클래스의 정확도, 정밀도, 재현율의 계산 및 분석은 테스트 데이터에 대해 수행되었습니다. 각 성과 지표의 계산 결과는 표와 같습니다.10. 이는 블랙아이스, 젖은 노면, 눈길의 정확도가 상대적으로 낮게 측정됨을 보여주는데, 이는 앞서 분석한 Confusion matrix와 같은 방식으로 빛의 특성을 상실한 결과로 추정된다. 그러나 정확도, 정밀도, 호출의 평균값은 0.982, 0.983, 0.983, 0.983이었고,

데이터가 학습과 관련이 없더라도 중요한 학습 결과를 생성한 것으로 간주됩니다.

표 10. 정확도, 정밀도, 등급별 결과 불러오기.

수업	정확성	정도	상기하다
도로	0.996	0.99	1.00
젖은 길	0.989	0.99	0.99
눈길	0.981	0.97	0.98
검은 얼음	0.961	0.98	0.96
평균	0.982	0.983	0.983

#### 4.2. 논의

2019년 12월 버지니아 고속도로 69대 추돌사고, 같은 해 12월 국내 영천고속도로 교통사고는 모두 블랙아이스가 원인이었다. 이렇듯 블랙아이스 사고로 인한 사상자는 전 세계적으로 계속해서 발생하고 있다. 이를 방지하기 위해 현재 홈파기(도로 표면에 작은 홈을 만들어 제동거리를 줄이는 공법) 설치, LED 표지판 설치, 도로에 열선 설치 등의 대책이 제시되고 있다. 그러나 제안된 조치는 사고 예방을 위한 사전 조치가 아니므로 블랙아이스 사고를 예방하기 위한 사전 대책을 강구하고 있습니다. 이에 AI 방법론을 활용해 블랙아이스를 사전에 감지해 높은 정확도로 추출하는 연구를 진행했다.

추가 확인으로 d 앞서 기존의 블랙아이스 감지 방식은 예방책을 제시할 것으로 기대된다. 빛으로 측정 [10,15]를 광원을 이용한 방법론으로 사용한다. 이러한 전략은 블랙아이스의 빛 반사 특성에 기인하며, 본 연구에서 사용한 이미지 데이터도 고려해야 한다. 분석 결과 확인된 바와 같이 Confusion matrix에서 블랙아이스와 눈길이 나타나는 것을 확인하였으며, 두 가지 범주의 열차 데이터를 통해 그 원인을 설명하도록 하겠습니다. 수치 7 열차 데이터의 RGB 버전을 보여줍니다. 검은 얼음 데이터는 lig의 반사를 보여주고 눈길 데이터는 눈 결정과 진창을 보여줍니다. 그러나 본 연구에서는 컴퓨팅의 한계로 신경망을 낮게 설계하여 GRAYSCALE로 변환을 진행하였다(그림 8), 이러한 특성을 명확하게 식별하기 어려웠고, 그 결과 두 클래스 사이의 혼란과 테스트 데이터의 블랙아이스 정확도가 상대적으로 낮았습니다.




그림 7.기차 데이터의 RGB 버전(검은 얼음과 눈길) 블랙아이스의 경우 빛 반사로 인해 반짝임을 알 수 있으며, 스노우 데이터의 경우 눈 결정과 슬러시가 나타난다.




그림 8.열차 데이터의 GRAYSCALE 버전(검은 얼음과 눈길); 이전 그림의 데이터에 비해 검은 얼음과 눈 결정 및 진창의 반사가 명확하게 식별되지 않습니다.

### 4.3. 신청방법

우리가 제안한 CNN 기반 블랙아이스 감지 방법을 활용할 수 있는 애플리케이션을 제안한다. AV와 CCTV에 탑재 안전사고를 예방할 수 있는 수단을 제공할 예정이다. 우선 차량에 부착된 카메라가 AV의 공학적 특성에 따라 블랙아이스 감지를 미리 학습해 블랙아이스를 미리 감지할 수 있을 것으로 기대된다. 또한 CCTV는 향후 C-ITS(Cooperative Intelligent Transport System)의 중요한 매개체가 될 것으로 예상돼 적절한 블랙아이스 사고 예측구역에 설치해 사고를 미연에 방지할 수 있을 것으로 기대된다.

## 5. 결론

본 연구는 AV에서 블랙아이스 사고를 예방하기 위해 CNN을 이용하여 육안으로 판단하기 어려운 블랙아이스를 검출하는 연구를 진행하였다. 4개의 클래스로 분류하여 데이터를 수집하고, 각 클래스의 학습 데이터, 검증 데이터, 테스트 데이터는 분할, 패딩, 증가 전처리를 통해 설정하였다. 본 연구에서 제안한 CNN 모델은 DCNN 모델과 달리 비교적 단순하게 설계되었으나 약 96%의 정확도로 우수한 성능을 보였다. 이는 복잡한 신경망 모델을 통해 계산량을 늘려 블랙아이스를 탐지하는 것보다 탐지 대상에 따라 신경망 깊이를 최적화하는 것이 더 효과적임을 시사한다. 또한 본 연구에서는 주로 새벽에 형성되는 블랙아이스의 특징으로 GRAYSCALE을 통해 신경망을 설계하고 학습하였으며, 그러나 일부 특정 클래스는 빛의 특성 손실로 인해 혼동되는 것으로 나타났습니다. 이에 향후 RGB 영상을 활용하여 블랙아이스 감지에 보다 최적화된 신경망 설계에 대한 연구를 진행할 계획이다. 또한 Google 이미지 검색을 통해 데이터를 수집했기 때문에 물체에 근접하여 감지된 이미지만 분류됩니다. 이에 따라 검출하고자 하는 물체까지의 거리와 각도를 다양하게 설정하여 다양한 상황에 적용 가능한 CNN 모델을 구축할 계획이다. 물체에 가깝게 감지된 이미지만 분류됩니다. 이에 따라 검출하고자 하는 물체까지의 거리와 각도를 다양하게 설정하여 다양한 상황에 적용 가능한 CNN 모델을 구축할 계획이다.[48-50](#)] 미래에.

이번 연구는 자율주행차 시대에도 잠재적 위험요인으로 꼽히는 블랙아이스를 센서와 파장이 아닌 인공지능을 이용해 감지했다는 점에서 의미가 있다. 이를 통해 자율주행차 블랙아이스 사고를 예방하고 향후 융합연구의 기초자료로 활용될 것으로 기대된다.

**저자 기여:** 개념화, MK 및 KH; 데이터 큐레이션, HL; 공식 분석, HL; 방법론, MK; 프로젝트 관리, MK 및 JS; 소프트웨어, HL; 감독, KH; 시각화, HL; 작문 - 원본 초안, HL, MK 및 KH; 쓰기-검토 및 편집, MK 및 KH 모든 저자는 원고의 출판된 버전을 읽고 이에 동의했습니다.

**자금 조달:** 본 연구는 교육부(제2020R1F1A106988411호)의 지원으로 한국연구재단 기초과학연구사업의 지원을 받아 수행되었습니다.

**이해 상충:** 저자는 이해 상충을 선언하지 않습니다.

## 참조

1. 이기광 전소일; 김현식; Kum, D. 자율주행차의 최적 경로 추적 제어: 적응형 전체 상태 선형 2차 가우시안(lqg) 제어. *IEEE 액세스* **2019년**, 7, 109120-109133. [[CrossRef](#)]
2. 상, S. *전국 자동차 충돌 사고 원인 조사(No. DOT HS 812 115)에서 조사된 충돌 사고의 주요 원인*, NHTSA 국립통계분석센터: 미국 워싱턴 DC, 2015.
3. 연방 교통 및 디지털 인프라부. *윤리위원회: 자율주행 및 커넥티드 드라이빙*, 연방 교통 및 디지털 인프라부: 독일 베를린, 2017.
4. 국립도로교통안전국. *연방 자동화 차량 정책: 도로 안전의 차세대 혁명 가속화*, 국립고속도로교통안전국: 미국 워싱턴 DC, 2016년.
5. 아브라함, H.; 이씨, 브래디, S.; 피츠제럴드, C.; 멜러, B.; 라이머, B.; Coughlin, JF 자율주행 차량 및 운전 대안: 신뢰, 선호도 및 연령 효과. 2017년 1월 8-12일 미국 워싱턴 DC에서 열린 교통 연구 위원회 96차 연례 회의 절차에서.

6. 장 티. 타오, D.; Qu, X.; 장 X.; 린, R.; Zhang, W. 대중의 자동화된 차량 수용에 있어 초기 신뢰와 지각된 위험의 역할. *운송 해상도 파트 C 비상. 기술.* **2019년**, *98*, 207–220. [CrossRef]
7. 하트위치, F.; Witzlack, C.; 베지아토, M.; Krems, JF 첫인상이 중요합니다. 고도로 자동화된 운전의 신뢰와 수용에 대한 결합된 운전 시뮬레이터 및 테스트 트랙 연구입니다. *운송 해상도 파트 F Tra파이c 사이코. 행동.* **2019년**, *65*, 522–535. [CrossRef]
8. 김구; 김비; Lee, K.; 고비; 이기중. 자율주행차량의 통합위험관리 기반 동적주행제어 설계. *IEEE 인텔. 운송 시스템 잡지.* **2017년**, *9*, 57–73. [CrossRef]
9. 뉴욕 타임즈 온라인. 사용 가능한 온라인: <https://www.nytimes.com/2020/10/26/technology/driverlesscars.html> (2020년 12월 3일 액세스).
10. 타바타바이, H.; Aljuboori, M. 도로와 교량에서 얼음과 물을 감지하기 위한 새로운 콘크리트 기반 센서. *센서* **2017년**, *17*, 2912. [CrossRef]
11. 알리마시, N.; Takahashi, S.; Enomoto, H. 도로 결빙 조건을 감지하기 위한 이동식 광학 시스템 개발. *황소. 글라시올. 해상도* **2012년**, *30*, 41–51. [CrossRef]
12. Abdalla, YE; 이크발, MT; Shehata, M. Kinect를 사용한 블랙 아이스 감지 시스템. 2017년 4월 30일~5월 3일 캐나다 온타리오주 윈저에서 전기 및 컴퓨터 공학에 관한 IEEE 30차 캐나다 회의(CCECE) 진행; 1~4쪽.
13. 미놀린, RG; 무스타핀, RG; 피스코바츠키, YV; Vedernikov, SG; Lavrent'ev, IS 로케이션 사운딩을 통해 송전선 전선에 검은 얼음과 성애가 쌓이는 것을 감지하는 기술입니다. *러스. 전기 공학* **2011년**, *82*, 541–543. [CrossRef]
14. 가일리우스, D.; Jačėnas, S. 타이어와 도로 마찰 초음파 소음을 분석하여 도로에서 얼음 감지. *울트라가사스 초음파* **2007년**, *62*, 17–20.
15. 엄마, X.; Ruan, C. 3파장 후방 산란 측정을 사용하여 도로에서 블랙 아이스를 감지하는 방법. *신청 고르다.* **2020년**, *59*, 7242–7246. [CrossRef]
16. 한제; 구비; Choi, K. 자율주행차를 위한 장애물 감지 및 인식 시스템. *수렴 Inf. 어린이에 속임수.* **2017년**, *7*, 229–235. (한국어)
17. 가오, H.; 첸 비; 왕제이; 리, 케이; Zhao, J.; Li, D. 자율주행차 환경에서 CNN 기반 시각과 LIDAR 융합을 이용한 객체 분류. *IEEE 트랜스. 인디알리.* **2018년**, *14*, 4224–4231. [CrossRef]
18. 아무르, N.; 알히크리, H.; Bazi, Y.; Benjdira, B.; Alajlan, N.; Zuair, M. UAV 이미지에서 차량 감지를 위한 딥 러닝 접근 방식. *원격 감지* **2017년**, *9*, 312. [CrossRef]
19. 나피이, MW; 유니아르노, EM; Affandi, A. Mask R-CNN을 사용한 차량 브랜드 및 유형 감지. 2019년 8월 28~29일 인도네시아 수라바야에서 열린 지능형 기술 및 그 응용에 관한 국제 세미나(ISITIA) 진행 중; 422~427쪽.
20. 장, L.; 린, 엘.; 리양, X.; He, K. 더 빠른 R-CNN이 보행자 감지에 잘 작동합니까? 컴퓨터 비전에 관한 유럽 회의 절차, 암스테르담, 네덜란드, 2016년 10월 11-14일; 443~457쪽.
21. 첸, YY; Jhong, SY; 리, GY; Chen, PH 더 빠른 r-cnn 및 지역 분해 분기를 사용하는 열 기반 보행자 감지. 지능형 신호 처리 및 통신 시스템(ISPACS)에 관한 국제 심포지엄 절차, 대만, 타이페이, 2019년 12월 3~6일; 1~2쪽.
22. 암마르, A.; 쿠바, A.; 아메드, M.; Saad, A. 컨볼루션 신경망을 사용한 자동차 감지를 위한 항공 이미지 처리: 더 빠른 r-cnn과 yolov3 간의 비교. *arXiv* **2019년**, arXiv:1910.07234.
23. Benjdira, B.; Khursheed, T.; 쿠바, A.; 암마르, A.; Ouni, K. 무인 항공기를 이용한 차량 감지: 더 빠른 r-cnn과 yolov3의 비교. 2019년 2월 5~7일 오만 무스카트에서 개최된 제1회 무인 차량 시스템 오만(UVS) 국제 회의 절차에서; 1~6쪽.
24. Xie, L.; 아마드, T.; 진엘; Liu, Y.; Zhang, S. 다중 방향 자동차 번호판 감지를 위한 새로운 CNN 기반 방법. *IEEE 트랜스. 인텔. 운송 시스템* **2018년**, *19*, 507–517. [CrossRef]
25. Yu, Y.; 진Q.; Chen, CW FF-CMnet: 기능 융합을 기반으로 하는 자동차 모델의 세분화된 분류를 위한 CNN 기반 모델입니다. IEEE International Conference on Multimedia and Expo(ICME) 간행물, San Diego, CA, USA, 2018년 7월 23-27일; 1~6쪽.
26. 푸트라, MH; 유소프, ZM; 임케이씨; Salim, SI yolo 프레임워크를 사용하여 사람과 자동차 감지를 위한 컨볼루션 신경망. *J. 텔레콤. 전자. 컴퓨팅 공학* **2018년**, *10*, 67–71.
27. 주, Z.; 리양, D.; 장, S.; 황, X.; 리비; Hu, S. 야생에서의 교통 표지 감지 및 분류. 컴퓨터 비전 및 패턴 인식에 관한 IEEE 회의 절차, 미국 네바다주 라스베이거스, 2016년 6월 27~30일; pp. 2110-2118.

28. Vennelakanti, A.; Shreya, S.; 라젠드란, R.; 사카르, D.; Muddegowda, D.; Hanagal, P. cnn 앙상블을 이용한 교통 표지 판 감지 및 인식. 2019년 1월 11~13일 미국 네바다주 라스베이거스에서 개최된 ICCE(International Conference on Consumer Electronics) 절차에서; 1~4쪽.
29. Alghmgham, DA; 라티프, G.; 알게조, J.; Alzubaidi, L. 심층 CNN을 사용한 자율 교통 표지(ATSR) 탐지 및 인식. *프로세디아/컴퓨터. 과학* **2019년**, *163*, 266~274. [CrossRef]
30. 피멘, M.; 메스만, B.; Corporaal, H. 컨볼루션 신경망에 의한 속도 표지판 감지 및 인식. 2011년 5월 16~17일, 네덜란드 아인트호벤에서 개최된 제8회 국제 자동차 회의 절차에서; 162~170쪽.
31. Malbog, 보행자 횡단보도 감지 및 인스턴스 분할을 위한 MA MASK R-CNN. 2019년 12월 20~21일 말레이시아 쿠알라룸푸르에서 개최된 IEEE 제6차 ICETAS(International Conference on Engineering Technologies and Applied Sciences) 회의에서; 1~5쪽.
32. 타베르닉, D.; Skočaj, D. 대규모 교통 표지판 감지 및 인식을 위한 딥 러닝. *IEEE 트랜스. 인텔. 운송 시스템* **2019년**, *21*, 1427~1440. [CrossRef]
33. Kukreja, R.; Rinchen, S.; Vaidya, B.; Mouftah, HT 자율 주행을 위해 더 빠른 R-CNN을 사용하여 교통 표지판 감지 평가. IEEE 25th International Workshop on Computer Aided Modeling and Design of Communication Links and Networks (CAMAD), 이탈리아 피사, 2020년 9월 14-16일; 1~6쪽.
34. 부제마, 캔자스; 베라다, I.; Bouhoue, A.; Boubouh, K. 컨볼루션 신경망을 이용한 교통 표지 인식. 2017년 11월 1~4일 모로코 라바트에서 개최된 WINCOM(International Conference on Wireless Networks and Mobile Communications) 절차에서; 1~6쪽.
35. Qian, R.; Liu, Q.; Yue, Y.; 코넨, F.; Zhang, B. 하이브리드 지역 제안 및 빠른 R-CNN을 사용한 도로 표면 교통 표지판 감지. 2016년 8월 13~15일 중국 창사에서 열린 제12회 자연 계산, 퍼지 시스템 및 지식 발견에 관한 제12회 국제 회의의 진행, 퍼지 시스템 및 지식 발견(ICNC-FSKD); 555~559쪽.
36. 슈스타노프, A.; 실시간 교통 표지 인식을 위한 Yakimov, P. CNN 설계. *프로세디아/공학* **2017년**, *201*, 718~725. [CrossRef]
37. 이현식; Kim, K. Convolutional Neural Network를 이용한 동시 교통 표지 검출 및 경계 추정. *IEEE 트랜스. 인텔. 운송 시스템* **2018년**, *19*, 1652~1663. [CrossRef]
38. Carrillo, J.; Crowley, M.; 팬, G.; Fu, L. 노변 카메라 영상과 날씨 데이터로부터 노면 상태를 결정하기 위한 효율적인 딥러닝 모델의 설계. *arXiv* **2020년**, arXiv:2009.10282.
39. 팬, 지.; Muresan, M.; 유라; Fu, L. 개선된 잔여 CNN을 이용한 실시간 겨울 노면 상태 모니터링. *할 수 있다. J. Civ. 공학* **2020년**. [CrossRef]
40. 상, J.; Shekhar, S. 마스크 r-cnn을 사용하여 스마트폰 캡처 이미지의 도로 손상 감지 및 분류. *arXiv* **2018년**, arXiv:1811.04535.
41. 통, Z.; Gao, J.; Han, Z.; Wang, Z. 심층 합성곱 신경망을 이용한 아스팔트 포장 균열 길이 인식. *도로 교인. 포장 데스*. **2018년**, *19*, 1334~1349. [CrossRef]
42. Li, B.; 왕, KC; 장아; 양은; Wang, G. 심층 합성곱 신경망을 이용한 포장 균열의 자동 분류. *국제 J. 포장 공학* **2020년**, *21*, 457~463. [CrossRef]
43. LeCun, Y.; Bottou, L.; Bengio, Y.; Haffner, P. 문서 인식에 적용된 그래디언트 기반 학습. *절차 IEEE* **1998년**, *86*, 2278~2324. [CrossRef]
44. 초비사, T.; Kashyap, M.; Chaitanya, KK Human Crawl vs Animal Movement and Person with Object Classifications Using CNN for Side-view Images from Camera. ICACCI(International Conference on Advances in Computing, Communications and Informatics) 진행, 인도 방갈로르, 2018년 9월 19~22일; 48~54쪽.
45. 케라스. 사용 가능한 온라인: <https://keras.io/> (2020년 11월 11일 액세스).
46. Nair, V.; Hinton, GE Rectified 선형 장치는 제한된 Boltzmann 기계를 개선합니다. 2010년 6월 21~24일 이스라엘 하이파에서 개최된 제27차 국제 기계 학습 국제 회의의 간행물.
47. Simonyan, K.; Zisserman, A. 대규모 이미지 인식을 위한 매우 깊은 컨볼루션 네트워크. *arXiv* **2014년**, arXiv:1409.1556.
48. 가드, M.; Newman, P. 인프라 없는 창고 탐색을 위한 프레임워크. 2015년 5월 26~30일 미국 워싱턴주 시애틀에서 개최된 ICRA(로봇 공학 및 자동화에 관한 IEEE 국제 회의) 간행물; 3271~3278쪽.
49. Tourani, S.; 데자이, D.; 미국 파리하르; Garg, S.; Sarvadevabhatla, RK; Krishna, KM Early Bird: 지각적으로 가명화된 실내 환경에 대한 반대 관점에서 루프 폐쇄. *arXiv* **2020년**, arXiv:2010.01421.

50. 첸, X.; 뎀파티, AS; Beardsley, P. 아래쪽을 향하는 카메라를 사용하여 지면에서 Streetmap 매핑 및 현지화. 지능형 로봇 및 시스템(IROS)에 관한 IEEE/RSJ 국제 회의 절차, 스페인 마드리드, 2018년 10월 1~5일; 1672~1679쪽.

**게시자 주:**MDPI는 발행된 지도 및 소속 기관의 관할권 주장과 관련하여 중립을 유지합니다.



©작가들의 2020. 사용권자 MDPI, 스위스 바젤. 이 기사는 CC BY(Creative Commons Attribution) 라이선스(<http://creativecommons.org/licenses/by/4.0/>)의 약관에 따라 배포되는 오픈 액세스 기사입니다.